

# EM 算法

W.J.Z

EM 算法是含有因变量的概率模型参数的极大似然估计方法，每代迭代由两步组成：E 步，求期望；M 步，求极大。本文只讲述 EM 算法和在高斯函数上的应用，算法的推导和收敛性证明请查阅相关资料。

## 1 EM 算法

一般用  $Y$  表示观测随机变量的数据， $Z$  表示隐随机变量的数据， $Y$  和  $Z$  连在一起成为完全数据，观测数据  $Y$  又称为不完全数据。假设给定观测数据  $Y$ ，其概率分布式  $P(Y|\theta)$ ，其  $\theta$  是需要估计的模型参数，那不完全数据  $Y$  的似然函数  $P(Y|\theta)$ 。对数似然函数  $L(\theta) = \log P(Y|\theta)$ 。假设  $Y$  和  $Z$  的联合概率分布为  $P(Y, Z|\theta)$ ，那么完全数据的对数似然函数是  $\log P(Y, Z|\theta)$ 。

---

**Algorithm 1:** EM 算法

---

**Input:** 观测变量数据  $Y$ ，隐变量数据  $Z$ ，联合分布  $P(Y, Z|\theta)$ ，条件分布  $P(Z|Y, \theta)$

**Output:** 模型参数  $\theta$

- 1 选择参数的初值  $\theta^0$ ，开始迭代。
- 2 E 步：记  $\theta^i$  为第  $i$  次迭代参数  $\theta$  的估计值，在第  $i+1$  次迭代的 E 步，计算

$$Q(\theta|\theta^i) = \sum_Z \log P(Y, Z|\theta) P(Z|Y, \theta^i)$$

$P(Z|Y, \theta^i)$  是在给定观测数据  $Y$  和当前的参数估计  $\theta^i$  下隐变量数据  $Z$  的条件概率分布。

- 3 M 步：求使  $Q(\theta, \theta^i) = \arg \max_{\theta} Q(\theta, \theta^i)$
  - 4 重复第二步和第三步，直到收敛。
-

## 2 EM 算法在高斯混合模型学习中的应用

高斯混合模型指具有以下形式的概率分布模型：

$$P(y|\theta) = \sum_{k=1}^K \alpha_k \phi(y|\theta_k)$$

其中,  $\alpha_k$  是系数,  $\alpha_k \geq 0, \sum_{k=1}^K \alpha_k = 1$ ;  $\phi(\theta|\theta_k)$  是高斯分布密度,  $\theta_k = (\mu_k, \sigma_k^2)$

$$\phi(y|\theta_k) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(y - \mu_k)^2}{2\sigma_k^2}\right)$$

观测数据  $y_j, j = 1, 2, \dots, N$  产生过程为：首先依概率  $\alpha_k$  选择第  $k$  个高斯分布模型  $\phi(y|\theta_k)$ ；然后依第  $K$  个分模型的概率分布  $\phi(y|\theta_k)$  生成观测数据  $y_j$ 。

$$\gamma_{jk} = \begin{cases} 1, & \text{第 } j \text{ 个观测数据来自第 } K \text{ 个分模型} \\ 0 & \text{否则} \end{cases} \quad \gamma_{jk} \in [0, 1]$$

完全数据的似然函数为

$$\begin{aligned} P(y, \gamma|\theta) &= \prod_{k=1}^K \prod_{j=1}^N [\alpha_k \phi(y_j|\theta_k)]^{\gamma_{jk}} \\ &= \prod_{k=1}^K \alpha_k^{n_k} \prod_{j=1}^N [\phi(y_j|\theta_k)]^{\gamma_{jk}} \\ &= \prod_{k=1}^K \alpha_k^{n_k} \prod_{j=1}^N \left[ \phi(y|\theta_k) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{(y - \mu_k)^2}{2\sigma_k^2}\right) \right]^{\gamma_{jk}} \end{aligned}$$

其中  $n_k = \sum_{j=1}^N \gamma_{jk}, \sum_{k=1}^K n_k = N$ 。完全数据的对数似然函数为

$$\log P(y, \gamma|\theta) = \sum_{k=1}^K \left\{ n_k \log \alpha_k + \sum_{j=1}^N \gamma_{jk} \left[ \log\left(\frac{1}{\sqrt{2\pi}\sigma_k}\right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right] \right\}$$

确定 Q 函数：

$$\begin{aligned} P(\gamma_{jk}|y, \theta) &= P(\gamma_{jk} = 1|y, \theta) \\ &= \frac{P(\gamma_{jk} = 1|y|\theta)}{\sum_{k=1}^K P(\gamma_{jk} = 1|y|\theta)} \\ &= \frac{\alpha_k \phi(y_j|\theta_k)}{\sum_{k=1}^K \alpha_k \phi(y_j|\theta_k)} \end{aligned}$$

Q 函数为:

$$Q(\theta, \theta^i) = \sum_Z \log P(y, \gamma | \theta) P(\gamma_{jk} | y, \theta)$$

求函数  $Q(\theta, \theta^i)$  对  $\theta$  的极大值, 分别对  $\mu_k, \sigma_k^2$  求偏导并令其为 0 即可得到解; 在  $\sum_{k=1}^K \alpha_k = 1$  条件下求偏导并令其为 0 得到其解。

$$\begin{aligned}\mu_k &= \frac{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk} y_j}{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk}} \\ \sigma_k^2 &= \frac{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk} (y_j - \mu_k)^2}{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk}} \\ \alpha_k &= \frac{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk}}{N}\end{aligned}$$

---

**Algorithm 2:** 高斯混合模型参数估计的 EM 算法

---

**Input:** 观测数据, 高斯混合模型

**Output:** 高斯混合模型参数

- 1 取参数的初始值开始迭代
- 2 E 步: 计算分模型  $k$  对观测数据  $y_j$  响应度

$$\frac{\alpha_k \phi(y_j | \theta_k)}{\sum_{k=1}^K \alpha_k \phi(y_j | \theta_k)}$$

- 3 M 步:

$$\begin{aligned}\mu_k &= \frac{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk} y_j}{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk}} \\ \sigma_k^2 &= \frac{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk} (y_j - \mu_k)^2}{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk}} \\ \alpha_k &= \frac{\sum_{j=1}^N P(\gamma_{jk} | y, \theta) \gamma_{jk}}{N}\end{aligned}$$

- 4 重复 2 和 3 步, 直至收敛。
-