

支持向量机

W.J.Z

1 硬间隔支持向量机

硬间隔指超平面能完全正确将数据划分为两类，法向量一侧为正类，相反一侧为负类，所有样本点都能满足函数间隔大于等于 1 的约束条件。超平面公式为：

$$w \cdot x + b = 0 \quad (1)$$

w 为支持向量， b 为位移项。

空间任意一点到超平面的距离为：

$$\frac{|w \cdot x + b|}{\|w\|} \quad (2)$$

对于完全正确分类的样本，令：

$$\begin{cases} w \cdot x_i + b \geq +1, & y_i = +1 \\ w \cdot x_i + b \leq -1, & y_i = -1 \end{cases} \quad (3)$$

两个离超平面最近的两个异类点相减得

$$w \cdot (x_1 - x_2) = \|w\| \cdot \|x_1 - x_2\| \cdot \cos \theta = 2 \quad (4)$$

$w \cdot (x_1 - x_2)$ 为向量相乘， θ 为两向量之间的夹角，而 $\|x_1 - x_2\| \cdot \cos \theta$ 就是我们所求的间隔。令 $d = \|x_1 - x_2\| \cdot \cos \theta$ ，则

$$d = \frac{2}{\|w\|} \quad (5)$$

原始问题可描述为：

$$\max_{w,b} \frac{2}{\|w\|} \quad (6)$$

$$s.t. \quad y_i (w \cdot x_i + b) \geq 1, \quad i = 1, 2, \dots, m \quad (7)$$

最大化 $\frac{1}{\|w\|}$ 等价于最小化 $\|w\|^2$, 公式 6 又可描述为

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (8)$$

$$s.t. \quad y_i (w \cdot x_i + b) \geq 1, \quad i = 1, 2, \dots, m$$

引入拉格朗日乘子进行对偶化:

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i \quad (9)$$

对 w 和 b 求偏导并令其等于 0 得:

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad (10)$$

$$\sum_{i=1}^N \alpha_i y_i = 0 \quad (11)$$

将公式 10 代入公式 9 和利用公式 11 得:

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (12)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (13)$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N \quad (14)$$

将求极大转为求极小:

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (15)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (16)$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N \quad (17)$$

假设最优化问题公式 15– 公式 17 对 α 的解为 a^* , 则

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \quad (18)$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \quad (19)$$

则分离超平面可以写成:

$$\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* = 0 \quad (20)$$

Algorithm 1: 硬间隔支持向量机

Input: 训练集 T

Output: 分离超平面和分类决策函数

1 构造并求解约束最优化问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

求得最优解 a^* .

2 计算

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

并选择 a^* 的一个正分量 $a_j^* > 0$ 计算 $b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$

3 求得分离超平面

$$w^* \cdot x + b^* = 0$$

分类决策函数:

$$f(x) = \text{sign}(w^* \cdot x + b^*)$$

2 软间隔支持向量机

软间隔是为了解决某些样本点不能满足函数间隔大于等于 1 的约束条件。约束条件和目标函数改变为：

$$y_i (w \cdot x_i + b) \geq 1 - \xi_i \quad (21)$$

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad (22)$$

ξ_i 为松弛变量， C 为惩罚函数， C 值大时对误分类的惩罚增大， C 值小时对误分类的惩罚减小。原始最优化问题的拉格朗日函数为：

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i (y_i (w \cdot x_i + b) - 1 + \xi_i) - \sum_{i=1}^N \mu_i \xi_i \quad (23)$$

其中 $\alpha_i \geq 0, \mu_i \geq 0$ ，对 w, b, ξ 求偏导并将其等于 0，得到的对偶问题为：

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad (24)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (25)$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N \quad (26)$$

假设 α^* 是对偶问题的一个解，存在 α^* 的一个分量 α_j^* ，使 $0 < \alpha_j^* < C$ 则：

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \quad (27)$$

$$b^* = y_j - \sum_{i=1}^N y_i \alpha_i^* (x_i \cdot x_j) \quad (28)$$

则分离超平面可以写成：

$$\sum_{i=1}^N \alpha_i^* y_j (x \cdot x_i) + b^* = 0 \quad (29)$$

分类决策函数可写成：

$$\text{sign}(\sum_{i=1}^N \alpha_i^* y_j (x \cdot x_i) + b^*) \quad (30)$$

Algorithm 2: 软间隔支持向量机

Input: 训练集 T

Output: 分离超平面和分类决策函数

- 1 选择惩罚参数 $C > 0$, 构造并求解凸二次规划问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

求得最优解 α^*

- 2 计算 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$, 选择 α^* 的一个分量 α_j^* 适合条件
 $0 < \alpha_j^* < C$ 计算

$$b^* = y_j - \sum_{i=1}^N y_i \alpha_i^* (x_i \cdot x_j)$$

- 3 求得分离超平面

$$w^* \cdot x + b^* = 0$$

分类决策函数

$$\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^*$$

3 非线性支持向量机

求解非线性问题的方法之一为将非线性问题进行一个非线性变换, 将非线性问题转换为线性问题, 步骤为: 首先使用一个变换将源空间的数据映射到新空间, 然后在新空间里用线性分类学习方法从训练数据中学习分类模型, 核技巧属于这种方法。

观察线性支持向量机的对偶问题, 无论是目标函数还是决策函数, 都只涉及输入实例和实例之间的内积, 在多普问题的目标函数中的内积 $x_i \cdot x_j$ 可以用核函数 $K(x_i, x_j)$ 来代替。

对偶问题为:

$$\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \quad (31)$$

分类决策函数为:

$$\text{sign}\left(\sum_{i=1}^N \alpha_i^* y_i K(x_i, x_j) + b^*\right) \quad (32)$$

Algorithm 3: 非线性支持向量机

Input: 训练集 T

Output: 分类决策函数

1 选择适当的核函数 K 和适当的参数 C , 构造并求解最优化问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, N \end{aligned}$$

求得最优解 α^*

2 选择 α^* 的一个正分量 α_j^* 适合条件 $0 < \alpha_j^* < C$ 计算

$$b^* = y_j - \sum_{i=1}^N y_i \alpha_i^* (x_i \cdot x_j)$$

3 构造决策函数

$$\text{sign}\left(\sum_{i=1}^N \alpha_i^* y_i K(x_i, x_j) + b^*\right)$$

4 * 当 $K(x, z)$ 是正定核函数时, 解释存在的

正定核的充要条件: 设 $K: \chi \times \chi \rightarrow R$ 是对称函数, 对任意 $x_i \in \chi, i = 1, 2, \dots, m, K(x, z)$ 对应的 Gram 矩阵是半正定矩阵。

定义： n 维欧氏空间中任意 $k(k \leq n)$ 个向量 $\alpha_1, \alpha_2, \dots, \alpha_k$ 的内积所组成的矩阵

$$\Delta(\alpha_1, \alpha_2, \dots, \alpha_k) = \begin{pmatrix} (\alpha_1, \alpha_1) & (\alpha_1, \alpha_2) & \dots & (\alpha_1, \alpha_k) \\ (\alpha_2, \alpha_1) & (\alpha_2, \alpha_2) & \dots & (\alpha_2, \alpha_k) \\ \dots & \dots & \dots & \dots \\ (\alpha_k, \alpha_1) & (\alpha_k, \alpha_2) & \dots & (\alpha_k, \alpha_k) \end{pmatrix}$$

称为 k 个向量 $\alpha_1, \alpha_2, \dots, \alpha_k$ 的格拉姆矩阵 (Gram矩阵), 它的行列式称为Gram行列式。

<http://blog.csdn.net/wangyang20170901>